金融工程

证券研究报告

2018 年 03 月 14 日

海外文献推荐 第 31 期

作者

吴先兴 分析师
SAC 执业证书编号：S1110516120001
wuxianxing@tfzq.com
18616029821

因子正交与系统性风险分解

作者提出了一种新颖的因子正交方法，该方法相对于传统的主成分分析以及施密特正交方法具有显著的优点，一是对于所有因子平等看待，二是该方法正交后得到的因子与原始因子保持了最大的相似性。基于该方法正交后的因子，我们可以方便地将系统性风险分解到各个因子上，并且衡量各因子对于资产系统性风险的相对贡献程度。

情景基本面，模型与主动管理

越来越多的实证研究表明，资产定价是基于条件的。这就对传统量化 alpha 模型背后一刀切的假设提出了质疑，而传统的多因子风险模型也具有类似的假设。为了更好地捕捉资产收益的横截面差异，提高主动管理的表现，本文提出了另一种方法来进行构建 alpha 模型。该方法包含三个步骤：1）根据股票的条件定价选择合适的划分情景的维度；2）确定各情景下，最佳的因子权重；3）将股票与各情景联系起来，从而确定股票最终的得分。尽管在本文的情景划分维度、alpha 因子选取、最大化 IR 的模型下，本文已经证明通过以上方式构建 alpha 模型的优点，但这并不是唯一的方法。此外，情景方法本质上是一个以风险维度为条件的分段线性模型。虽然这可能是最简单并且尽可能避免数据挖掘的非线性模型，也有其他方法来构造非线性预测模型。

风险提示：本报告内容基于相关文献，不构成投资建议。

相关报告

1《金融工程：金融工程-市场情绪一览 2018-03-13》 2018-03-13

2《金融工程：金融工程-市场情绪一览 2018-03-12》 2018-03-12

3《金融工程：金融工程-量化选股策略跟踪》 2018-03-12

内容目录

图表目录

因子正交与系统性风险分解

文献来源：Klein, Rudolf F., and V. K. Chow. "Orthogonalized factors and systematic risk decomposition." Quarterly Review of Economics & Finance 53.2(2013):175-187.

推荐原因：本文提出了一种新颖的因子正交方法，该方法相对于传统的主成分分析以及施密特正交方法具有显著的优点，一是对于所有因子平等看待，二是该方法正交后得到的因子与原始因子保持了最大的相似性。基于该方法正交后的因子，我们可以方便地将系统性风险分解到各个因子上，并且衡量各因子对于资产系统性风险的相对贡献程度。

1. 简介

本文的目标是提出一种最优化的方法来对一系列公共因子提取出互不相关的成分，这样就能够消除因子间的线性依赖，并且资产的波动率就可以被简单分解为因子的波动率。在传统的多元线性回归模型下，资产的收益率可以被多因子进行解释，回归得到的因子的 beta 系数虽然能在一定程度上反映资产的波动率与因子波动率的关系，但是资产的波动率还受因子间的协方差影响。为了能够对资产的波动率进行分解，我们需要将因子进行分解得到一些互不相关的成分，这样资产的波动率就可以简单分解为这些成分的波动率。

本文提出了一种最优化、公平的正交化方法来对因子收益进行正交。这些正交后的因子能够保持原始资产的方差，而因子之间的协方差为 0。并且，对正交后因子对于收益的解释能力和原始因子的解释能力相同。因此，根据正交后因子的波动率以及回归系数，我们就可以方便地将系统性风险分解到各个因子上。

2. 正交过程

假设一个风险资产 j 的收益可以被 K 个因子 f^k 线性解释，例如市场(RM)，规模(SMB)，价值(HML)，动量(Mom)，长期反转(Rev)，线性因子模型表达式如下：

$$r_t^j = \alpha_j + \Sigma_{k=1}^{K} \beta_{k_j} f_t^k + \varepsilon_t^j$$

其中 f^k 和残差项 ε_j 不相关，但是因子之间可能相关。

资产 j 的收益方差可以表示为

$$\sigma_{s_j}^2 = \Sigma_{l=1}^{K} \Sigma_{k=1}^{K} \beta_{k_j} \beta_{l_j} Cov(f^k, f^l)$$

而可决系数 R-square 可以表示为 $\frac{\sigma_{s_j}^2}{\sigma_j^2}$。组合的波动不仅决定于因子的 beta 系数，还决定于因子之间的协方差。当因子之间没有多重共线性，即协方差为 0 时，我们才能很方便地将组合的波动分解到各个因子上。

我们以 $f_{T\times 1}^k = [f_1^k, f_2^k, \dots, f_T^k]'$ $(1 \le k \le K)$ 表示第 k 个因子的收益序列，$F_{T\times K} = [f_t^k]_{t=1,\dots,T}^{k=1,\dots,K}$ 表示因子收益矩阵，T 表示时间区间，K 表示因子数量。我们的目标是从 $F_{T\times K}$ 出发生成一个新的矩阵 $F_{T\times K}^{\perp} = \left[f_t^{k^\perp}\right]_{t=1,\dots,T}^{k=1,\dots,K}$，矩阵的任何两列都互不相关并且能够保持方差不变，如此则我们可以将资产收益的方差表达为如下形式：

$$\hat{\sigma}_{s_j}^2 = \left(\hat{\beta}_{1_j}^{\perp} \hat{\sigma}_{f^1}^{\perp}\right)^2 + \left(\hat{\beta}_{2_j}^{\perp} \hat{\sigma}_{f^2}^{\perp}\right)^2 + \cdots + \left(\hat{\beta}_{K_j}^{\perp} \hat{\sigma}_{f^K}^{\perp}\right)^2 = \Sigma_{\mathrm{k}=1}^{K} \left(\hat{\beta}_{k_j}^{\perp} \hat{\sigma}_{f^k}^{\perp}\right)^2 = \hat{\sigma}_j^2 - \hat{\sigma}_{\varepsilon_j}^2$$

其中 $\hat{\sigma}_{s_j}^2$ 为 $\sigma_{s_j}^2$ 的估计，$\hat{\beta}^{\perp}$ 和 $\hat{\sigma}^{\perp}$ 分别为正交后得到的因子 beta 和标准差，$\hat{\sigma}_j^2$ 和 $\hat{\sigma}_{\varepsilon_j}^2$ 分别为资产 j 的估计方差和剩余方差。

我们对 $F_{T\times K}$ 各因子减去其均值，得到 $\tilde{F}_{T\times K}=[\tilde{f}_t^k]_{t=1,\dots,T}^{k=1,\dots,K}=[f_t^k-\bar{f}^k]_{t=1,\dots,T}^{k=1,\dots,K}$。我们定义一个从 $\tilde{F}_{T\times K}$ 到 $\tilde{F}_{T\times K}^{\perp}$ 的线性变换矩阵 $S_{K\times K}$，满足

$$\tilde{F}_{T\times K}^{\perp}=\tilde{F}_{T\times K}S_{K\times K}$$

为了得到 $S_{K\times K}$，我们首先要计算 $\tilde{F}_{T\times K}$ 的协方差矩阵 $\Sigma_{K\times K}$，$\tilde{F}_{T\times K}$ 的重叠矩阵 $M_{K\times K}=(\mathrm{T}-1)\Sigma_{K\times K}$。$\tilde{F}_{T\times K}^{\perp}$ 为正交矩阵，则其满足

$$\left(\tilde{F}_{T\times K}^{\perp}\right)'\tilde{F}_{T\times K}^{\perp}=\left(\tilde{F}_{T\times K}S_{K\times K}\right)'\tilde{F}_{T\times K}S_{K\times K}=S_{K\times K}'\left(\tilde{F}_{T\times K}'\tilde{F}_{T\times K}\right)S_{K\times K}=S_{K\times K}'M_{K\times K}S_{K\times K}=I_{K\times K}$$

故有

$$S_{K\times K}S_{K\times K}'=M_{K\times K}^{-1}$$

其通解为

$$S_{K\times K}=M_{K\times K}^{-1/2}C_{K\times K}$$

其中 $C_{K\times K}$ 为一个任意的正交矩阵。当取 $C_{K\times K}=I_{K\times K}$ 时，该正交过程称为对称正交。

为了计算得到 $S_{K\times K}$，我们可以对 $M_{K\times K}$ 进行特征分解得到特征向量 $O_{K\times K}$和特征根对角阵 $D_{K\times K}$，满足 $M_{K\times K}=O_{K\times K}D_{K\times K}O_{K\times K}^{-1}$，由此可以得到

$$S_{K\times K}=O_{K\times K}D_{K\times K}^{-1/2}O_{K\times K}'$$

最后，我们将正交后的因子再缩放其方差和原始因子一致，缩放过程如下：

$$S_{K\times K}\mapsto S_{K\times K}\sqrt{T-1}\begin{bmatrix}\sigma_1 & 0 & \cdots & 0\\ 0 & \sigma_2 & \cdots & 0\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & \sigma_K\end{bmatrix}$$

其中 σ_k 为因子 k 的标准差。

由此我们可以得到对称正交变换后的正交矩阵$\tilde{F}_{T\times K}^{\perp}$。下面我们来计算 $F_{T\times K}^{\perp}$，

$$\tilde{F}_{T\times K}^{\perp}+\mathbf{1}_{T\times 1}\bar{F}_{1\times K}S_{K\times K}=\tilde{F}_{T\times K}S_{K\times K}+\mathbf{1}_{T\times 1}\bar{F}_{1\times K}S_{K\times K}$$
$$=\left(\tilde{F}_{T\times K}+\mathbf{1}_{T\times 1}\bar{F}_{1\times K}\right)S_{K\times K}=F_{T\times K}S_{K\times K}=F_{T\times K}^{\perp}$$

其中 $\mathbf{1}_{T\times 1}$ 为全 1 的向量，$\bar{F}_{1\times K}$ 为 $F_{T\times K}$ 的均值。

进一步，根据正交后的因子，我们可以对回归的拟合优度进行分解：

$$\mathrm{R}_j^2=\Sigma_{\mathrm{k}=1}^{K}\mathrm{DR}_{\mathrm{j,k}}^2,\ \mathrm{DR}_{\mathrm{j,k}}^2=\left(\hat{\beta}_{k_j}^{\perp}\frac{\hat{\sigma}_{f^k}}{\hat{\sigma}_j}\right)^2$$

因此拟合优度也能分解到各个正交后的因子上，来表征各因子对于资产方差的相对贡献度。

3. 实验对比

当前已经有一些正交化的方法用于因子的正交化，例如主成分分析（PCA）或者 Gram-Schmidt（GS）方法等。PCA 的方法对因子进行降维，正交后的因子和原始因子没有一一映射的关系，和原始因子的相似性的维持能力也较差。而 GS 方法需要给定一个正交的顺序，无法公平地对待每个因子。

本节我们对比对称正交(SW/L)方法和这些方法的效果。下图展示了 5 因子市场(RM)、规模(SMB)、价值(HML)、动量(Mom)、长期反转(Rev)中任意两个因子组合在正交前后因子

取值的相关系数、正交前后因子暴露矩阵的距离。5 因子数据来源为 Kenneth French 的数据库 http://mba.tuck.dartmouth.edu/pages/faculty/ken.french/，测试数据选取 1931 年 1 月至 2008 年 12 月的月度数据。

图 1：正交化方法的比较

Panel A: Correlation coefficients between the original and the orthogonalized factors

	SW/L		PCA		GS	
(1)	(2)	(3)	(4)	(5)	(6)	(7)
RM & *SMB*	0.992	0.978	0.986	0.874	1.000	0.941
RM & *HML*	0.996	0.990	0.987	0.922	1.000	0.970
RM & *Mom*	0.987	0.982	0.909	0.709	1.000	0.946
RM & *Rev*	0.995	0.989	0.988	0.920	1.000	0.968
SMB & *HML*	0.999	0.999	0.869	0.913	1.000	0.994
SMB & *Mom*	0.996	0.998	0.957	0.990	1.000	0.991
SMB & *Rev*	0.976	0.979	0.590	0.871	1.000	0.908
HML & *Mom*	0.972	0.984	0.746	0.952	1.000	0.925
HML & *Rev*	0.947	0.945	0.904	0.450	1.000	0.787
Mom & *Rev*	0.994	0.990	0.970	0.882	1.000	0.975

Panel B: Frobenius norm values of the deviation matrix

	SW/L	PCA	GS
RM & *SMB*	30.518	57.877	35.994
RM & *HML*	22.171	51.239	29.428
RM & *Mom*	38.748	128.797	54.975
RM & *Rev*	22.824	50.529	28.768
SMB & *HML*	7.465	70.009	17.464
SMB & *Mom*	12.920	36.675	30.671
SMB & *Rev*	31.769	123.197	47.165
HML & *Mom*	37.327	88.974	63.458
HML & *Rev*	51.105	116.381	71.404
Mom & *Rev*	21.661	63.158	28.691

资料来源：The Quarterly Review of Economics and Finance，天风证券研究所

从上图 Panel A 中可以看到，对称正交方法因子正交前后的相关系数最低为 0.945，而 PCA 方法正交前后的相关系数最低为 0.45，GS 方法正交前后的相关系数最低为 0.787。GS 方法不修改第一个因子，因此第一个因子正交前后完全不变，第二个因子的相关系数大部分比 PCA 方法的相关系数要高，因子在这 10 种情况中 GS 方法要好于 PCA 方法。

上图 Panel B 中比较了正交前后因子矩阵的 Frobenius 范数，用于考察正交前后因子矩阵的距离。可以看到，在 10 种情况中，对称正交方法都取得了最小的距离，而 PCA 的方法距离最大，因此大部分使用 PCA 的方法后都会对正交后因子进行旋转来贴近原始因子。下图展示了正交前后因子的收益情况以及因子间的相关系数情况。

图 2：正交前后因子收益及相关系数

Panel A: Distribution parameters

	Original returns					Orthogonal returns				
	RM	*SMB*	*HML*	*Mom*	*Rev*	$RM^{\perp}$	$SMB^{\perp}$	$HML^{\perp}$	$Mom^{\perp}$	$Rev^{\perp}$
Mean	0.61	0.29	0.44	0.70	0.35	0.67	0.23	0.55	0.99	0.17
Std. Dev.	5.40	3.36	3.61	4.71	3.54	5.40	3.36	3.61	4.71	3.54
Skewness	0.30	2.29	1.91	−3.04	2.95	−0.24	1.44	0.63	−2.04	1.97
Kurtosis	8.34	22.99	16.11	28.33	24.22	4.82	14.89	5.54	15.45	17.40

Panel B: Correlation coefficients

Factor	*Original returns*					Factor	*Orthogonal Returns*				
	RM	*SMB*	*HML*	*Mom*	*Rev*		$RM^{\perp}$	$SMB^{\perp}$	$HML^{\perp}$	$Mom^{\perp}$	$Rev^{\perp}$
RM	1	0.33	0.23	−0.34	0.24	$RM^{\perp}$	1	0.00	0.00	0.00	0.00
SMB		1	0.10	−0.15	0.41	$SMB^{\perp}$	0.00	1	0.00	0.00	0.00
HML			1	−0.40	0.61	$HML^{\perp}$	0.00	0.00	1	0.00	0.00
Mom				1	−0.24	$Mom^{\perp}$	0.00	0.00	0.00	1	0.00
Rev					1	$Rev^{\perp}$	0.00	0.00	0.00	0.00	1

资料来源：The Quarterly Review of Economics and Finance，天风证券研究所

从 Panel A 可以看到，正交前后因子的标准差是一致的。从 Panel B 可以看到，原始因子的相关系数较高，尤其是 HML 和 Rev 相关系数有 0.61。而正交后各因子的相关系数为 0。下表展示了对一些风格资产进行回归时，正交前后因子的 beta 系数。图中括号内为 t 值，*、**、***分别表示显著度 10%，5%，1%。

图 3：正交前后因子的 Beta 系数

		Original factor returns					Orthogonal factor returns				
		$\hat{\beta}_{RM}$	$\hat{\beta}_{SMB}$	$\hat{\beta}_{HML}$	$\hat{\beta}_{Mom}$	$\hat{\beta}_{Rev}$	$\hat{\beta}^{\perp}_{RM}$	$\hat{\beta}^{\perp}_{SMB}$	$\hat{\beta}^{\perp}_{HML}$	$\hat{\beta}^{\perp}_{Mom}$	$\hat{\beta}^{\perp}_{rev}$
Small	Growth	1.0574	1.2421	−0.0920	−0.1910	−0.0497	1.2014	1.3960	0.0570	−0.4066	0.3140
		(71.27)***	(49.58)***	(−3.35)***	(−11.04)***	(−1.74)*	(91.01)***	(65.74)***	(2.89)***	(−26.83)***	(15.60)***
	Value	0.9608	1.1961	0.7280	−0.1635	0.1746	1.1754	1.3774	0.8635	−0.5134	0.7587
		(72.90)***	(53.74)***	(29.81)***	(−10.64)***	(6.87)***	(100.22)***	(73.01)***	(49.23)***	(−38.13)***	(42.42)***
	Down Mom	0.9905	1.2869	0.3427	−0.5859	0.1473	1.2496	1.4907	0.5957	−0.8649	0.6730
		(54.10)***	(41.63)***	(10.10)***	(−27.43)***	(4.17)***	(76.70)***	(56.88)***	(24.45)***	(−46.25)***	(27.09)***
	Low Rev	0.9855	1.3605	0.4973	−0.2119	0.4186	1.2281	1.5944	0.7413	−0.5512	0.9482
		(53.96)***	(44.12)***	(14.69)***	(−9.95)***	(11.88)***	(75.57)***	(60.99)***	(30.50)***	(−29.55)***	(38.26)***
Big	Growth	1.0596	0.1975	−0.2226	−0.0915	−0.0556	1.0504	0.3913	−0.0842	−0.2433	0.0476
		(142.42)***	(15.72)***	(−16.15)***	(−10.54)***	(−3.87)***	(158.65)***	(36.74)***	(−8.51)***	(−32.01)***	(4.72)***
	Value	1.1188	0.2258	0.8116	−0.1189	−0.0012	1.1968	0.4413	0.8944	−0.4569	0.4438
		(115.98)***	(13.86)***	(45.40)***	(−10.56)***	(−0.07)	(139.43)***	(31.97)***	(69.68)***	(−46.37)***	(33.90)***
	Down Mom	1.1379	0.2065	0.1419	−0.6348	−0.0227	1.2410	0.4547	0.3867	−0.8455	0.2580
		(128.65)***	(13.82)***	(8.66)***	(−61.53)***	(−1.33)	(157.68)***	(35.92)***	(32.86)***	(−93.59)***	(21.49)***
	Low Rev	1.1225	0.1000	0.2132	−0.0957	0.6474	1.1856	0.4589	0.5447	−0.3778	0.8175
		(107.02)***	(5.65)***	(10.97)***	(−7.82)***	(31.98)***	(127.02)***	(30.57)***	(39.03)***	(−35.27)***	(57.44)***

资料来源：The Quarterly Review of Economics and Finance，天风证券研究所

可以看到，由于正交后剔除了因子的共线性，回归得到的 beta 系数会更加稳定。下表展示了正交前后因子对于资产波动的分解情况。

图 4：正交前后资产系统性风险分解

		Original factor returns						$\hat{\sigma}^2_{sr_j}$	Orthogonal factor returns					
		$\hat{\beta}^2_{RM_j}\hat{\sigma}^2_{RM}$	$\hat{\beta}^2_{SMB_j}\hat{\sigma}^2_{SMB}$	$\hat{\beta}^2_{HML_j}\hat{\sigma}^2_{HML}$	$\hat{\beta}^2_{Mom_j}\hat{\sigma}^2_{Mom}$	$\hat{\beta}^2_{Rev_j}\hat{\sigma}^2_{Rev}$	Sum		Sum	$\hat{\beta}^{\perp 2}_{RM_j}\hat{\sigma}^2_{RM}$	$\hat{\beta}^{\perp 2}_{SMB_j}\hat{\sigma}^2_{SMB}$	$\hat{\beta}^{\perp 2}_{HML_j}\hat{\sigma}^2_{HML}$	$\hat{\beta}^{\perp 2}_{Mom_j}\hat{\sigma}^2_{Mom}$	$\hat{\beta}^{\perp 2}_{Rev_j}\hat{\sigma}^2_{Rev}$
Panel A: Equally-weighted portfolios														
Small	Growth	32.635	17.408	0.111	0.808	0.031	50.993	69.060	69.060	42.131	21.987	0.042	3.663	1.237
	Value	26.948	16.140	6.919	0.592	0.383	50.982	84.527	84.527	40.326	21.404	9.732	5.839	7.226
	Down Mom	28.638	18.685	1.533	7.605	0.273	56.734	97.544	97.544	45.584	25.070	4.632	16.572	5.685
	Low Rev	28.352	20.884	3.228	0.995	2.199	55.659	97.899	97.899	44.028	28.681	7.174	6.732	11.285
Big	Growth	32.775	0.440	0.647	0.186	0.039	34.086	35.364	35.364	32.205	1.727	0.093	1.311	0.028
	Value	36.535	0.575	8.597	0.313	0.000	46.020	61.546	61.546	41.811	2.198	10.441	4.624	2.472
	Down Mom	37.795	0.481	0.263	8.930	0.006	47.475	65.914	65.914	44.956	2.333	1.952	15.837	0.835
	Low Rev	36.777	0.113	0.593	0.203	5.261	42.947	58.829	58.829	41.028	2.376	3.873	3.163	8.389
Panel B: Value-weighted portfolios														
Small	Growth	35.031	12.247	0.573	0.077	0.005	47.934	60.757	60.757	41.353	16.771	0.036	1.527	1.070
	Value	30.189	9.482	7.277	0.043	0.020	47.011	69.520	69.520	39.879	13.301	8.759	3.351	4.231
	Down Mom	33.885	10.951	0.820	6.991	0.003	52.649	84.143	84.143	47.599	15.982	2.940	14.854	2.768
	Low Rev	32.547	12.922	2.102	0.179	1.692	49.442	80.699	80.699	44.267	19.441	5.001	3.788	8.202
Big	Growth	29.899	0.119	0.732	0.010	0.001	30.760	27.709	27.709	26.914	0.124	0.123	0.538	0.011
	Value	34.718	0.006	8.500	0.028	0.001	43.253	52.456	52.456	37.316	0.621	9.800	2.887	1.832
	Down Mom	33.913	0.063	0.017	10.154	0.000	44.146	56.307	56.307	38.473	0.370	1.157	15.895	0.412
	Low Rev	33.221	0.237	0.026	0.046	8.436	41.966	49.210	49.210	34.934	0.691	2.384	1.907	9.294

资料来源：The Quarterly Review of Economics and Finance，天风证券研究所

可以看到，正交后因子的风险贡献和与总体的系统性风险一致，而原始因子的风险贡献和明显与总体的系统性风险不一致。

4. 总结

本文提出了一种最优化、公平的对称正交方法来对因子收益进行正交。这些正交后的因子能够保持原始资产的方差，而因子之间的协方差为 0。并且，对称正交后因子对于收益的解释能力和原始因子的解释能力相同，正交后的因子对于原始因子保持了最大的相似性。根据正交后因子的波动率以及回归系数，我们就可以方便地将系统性风险分解到各个因子上，并且衡量各因子对于资产系统性风险的相对贡献程度。

情景基本面，模型与主动管理

文献来源：Sorensen E H, Hua R, Qian E E. Contextual Fundamentals, Models, and Active Management[J]. Journal of Portfolio Management 32.1(2005):23-36.

推荐原因：本文提出了一种构建情景模型的方法。该方法包含三个步骤：1）根据股票的条件定价选择合适的划分情景的维度；2）确定各情景下，最佳的因子权重；3）将股票与各情景联系起来，从而确定股票最终的得分。

1. 简介

越来越多的实证研究表明，资产定价是基于条件的。这就对传统量化 alpha 模型背后一刀切的假设提出了质疑，而传统的多因子风险模型也具有类似的假设。为了更好地捕捉资产收益的横截面差异，提高主动管理的表现，本文提出了另一种方法来进行构建 alpha 模型。该方法包含三个步骤：1）根据股票的条件定价选择合适的划分情景的维度；2）确定各情景下，最佳的因子权重；3）将股票与各情景联系起来，从而确定股票最终的得分。尽管在本文的情景划分维度、alpha 因子选取、最大化 IR 的模型下，本文已经证明通过以上方式构建 alpha 模型的优点，但这并不是唯一的方法。此外，情景方法本质上是一个以风险维度为条件的分段线性模型。虽然这可能是最简单并且尽可能避免数据挖掘的非线性模型，也有其他方法来构造非线性预测模型。

2. 划分情景

从三个风险维度考察因子之间的相互作用：估值，成长，盈利稳定性。在每一个维度，分别构建两个数量相等且互不重合的组合，其中一个组合由该风险特征最高的部分股票构成，另一个组合由该风险特征最低的部分股票构成。因此，可获得六个情景。然后，比较各个情景下各因子风险调整后的 IC。

图 5：不同风险维度下各因子风险调整后 IC 的比较

Comparison of Risk-Adjusted ICs in Different Risk Dimensions

PANEL A: VALUE DIMENSION

	Mean		STD		Two Sample t Test		F Test			
	High	Low	High	Low	t	p value	F	pval	df(num)	df(denom)
RV	0.022	0.022	0.069	0.079	0.011	0.991	0.764	0.270	68	68
OE	0.032	0.040	0.047	0.037	-1.050	0.296	1.613	0.051	68	68
AA	0.027	0.042	0.043	0.050	-1.912	0.058	0.720	0.177	68	68
EF	0.044	0.015	0.041	0.057	3.460	0.001	0.504	0.005	68	68
MO	0.031	0.049	0.061	0.072	-1.577	0.117	0.711	0.163	68	68

PANEL B: GROWTH DIMENSION

	Mean		STD		Two Sample t Test		F Test			
	High	Low	High	Low	t	p value	F	pval	df(num)	df(denom)
RV	0.003	0.034	0.113	0.062	-2.046	0.043	3.318	0.000	68	68
OE	0.061	0.019	0.043	0.042	5.702	0.000	1.037	0.883	68	68
AA	0.044	0.022	0.060	0.039	2.461	0.015	2.450	0.000	68	68
EF	0.028	0.017	0.054	0.043	1.274	0.205	1.567	0.066	68	68
MO	0.059	0.023	0.092	0.072	2.571	0.011	1.623	0.048	68	68

PANEL C: VARIABILITY DIMENSION

	Mean		STD		Two Sample t Test		F Test			
	High	Low	High	Low	t	p value	F	pval	df(num)	df(denom)
RV	0.023	0.023	0.105	0.076	-0.025	0.980	1.911	0.008	68	68
OE	0.045	0.029	0.051	0.039	2.019	0.046	1.678	0.034	68	68
AA	0.033	0.032	0.049	0.036	0.151	0.880	1.848	0.012	68	68
EF	0.038	0.018	0.055	0.045	2.343	0.021	1.492	0.101	68	68
MO	0.034	0.038	0.094	0.074	-0.252	0.802	1.605	0.053	68	68

资料来源：Journal of Portfolio Management，天风证券研究所

3. 最优因子权重

在六个情境下，通过最大化 IR 的方式，确定各因子的最优权重。可以通过多种方式比较各情境下的因子模型是否存在显著差异，如直接比较因子权重（Bootstrapping 算法），如图 6 所示。

图 6：不同风险维度下因子权重的重复抽样比较

Resampled Weight Comparison in Different Risk Dimensions

PANEL A: VALUE DIMENSION

	Mean		STD		Difference (High-Low)		
	High	Low	High	Low	Avg/Stdr	Avg	Stdr
RV	9.0	6.3	4.0	3.5	0.5	2.6	5.3
OE	16.7	46.4	6.0	8.9	-2.7	-29.7	10.8
AA	20.4	24.4	6.2	6.5	-0.4	-4.0	9.0
EF	43.0	5.1	7.9	4.8	4.1	37.9	9.3
MO	11.0	17.8	4.8	5.1	-1.0	-6.8	7.1

PANEL B: GROWTH DIMENSION

	Mean		STD		Difference (High-Low)		
	High	Low	High	Low	Avg/Stdr	Avg	Stdr
RV	3.7	22.8	2.4	7.3	-2.5	-19.1	7.6
OE	52.7	16.9	7.8	8.3	3.1	35.8	11.7
AA	16.7	33.3	5.0	8.8	-1.6	-16.6	10.1
EF	14.0	16.7	5.9	7.2	-0.3	-2.7	9.3
MO	12.9	10.3	4.0	5.0	0.4	2.6	6.3

PANEL C: VARIABILITY DIMENSION

	Mean		STD		Difference (High-Low)		
	High	Low	High	Low	Avg/Stdr	Avg	Stdr
RV	7.9	7.2	3.8	4.5	0.1	0.7	5.9
OE	36.1	27.0	7.4	6.5	0.9	9.1	10.0
AA	27.2	41.1	6.3	7.5	-1.4	-13.9	9.6
EF	22.5	10.5	6.6	5.1	1.4	12.0	8.4
MO	6.4	14.2	3.7	4.4	-1.4	-7.9	5.7

资料来源：Journal of Portfolio Management，天风证券研究所

图 6 独立比较了各因子的权重差别，也可以联合检验两个因子模型之间的差异。可以由两种方法。第一种方法衡量两个模型间的距离，即

$$d = \sqrt{\frac{\Delta w \times \Delta w}{k}}$$

其中，$\Delta w = w_{model1} - w_{model2}$为两个模型的权重差，$k$为模型中的因子数量，本文中为 5。因此，$d$衡量的两个模型权重差别的均方根。检验结果如图 7 中 B 所示。

模型的距离没有考虑抽样误差的问题，而第二种方法可以弥补这一缺陷，即对模型差异进行卡方检验（Chi-square test）。如图 7 中 C、D 所示。

图 7：模型权重比较

Pairwise Model Weight Comparison

PANEL A: MODEL WEIGHTS OF RESAMPLED EFFICIENT PORTFOLIOS

		RV	OE	AA	EF	MO
One-size	R1000	2.5	41.6	36.3	13.0	6.5
Value	High	9.0	16.7	20.4	43.0	11.0
	Low	6.3	46.4	24.4	5.1	17.8
Growth	High	3.7	52.7	16.7	14.0	12.9
	Low	22.8	16.9	33.3	16.7	10.3
Variability	High	7.9	36.1	27.2	22.5	6.4
	Low	7.2	27.0	41.1	10.5	14.2

PANEL B: MODEL DISTANCE

		One-size	Value		Growth		Variable	
		R1000	High	Low	High	Low	High	Low
One-size	R1000	0.0	21.2	9.4	11.7	12.7	7.1	8.7
Value	High	21.2	0.0	24.4	23.2	14.6	14.7	20.0
	Low	9.4	24.4	0.0	7.1	16.9	11.7	13.2
Growth	High	11.7	23.2	7.1	0.0	19.8	11.2	17.8
	Low	12.7	14.6	16.9	19.8	0.0	10.7	7.4
Variability	High	7.1	14.7	11.7	11.2	10.7	0.0	11.0
	Low	8.7	20.0	13.2	17.8	7.4	11.0	0.0

PANEL C: CHI-SQUARED STATISTICS

		One-size	Value		Growth		Variable	
		R1000	High	Low	High	Low	High	Low
One-size	R1000	0.0	31.8	13.2	19.8	13.5	5.6	7.7
Value	High	69.0	0.0	65.6	39.1	15.9	13.8	49.0
	Low	32.0	36.2	0.0	5.2	21.6	17.0	11.1
Growth	High	16.6	39.7	5.0	0.0	24.9	13.1	19.4
	Low	73.7	18.9	34.0	74.7	0.0	24.2	18.3
Variability	High	11.9	13.7	17.7	14.2	8.6	0.0	9.7
	Low	17.0	23.2	9.9	24.8	7.7	14.0	0.0

PANEL D: P-VALUE OF CHI-SQUARED TEST

		One-size	Value		Growth		Variable	
		R1000	High	Low	High	Low	High	Low
One-size	R1000	1.000	0.000	0.010	0.001	0.009	0.235	0.103
Value	High	0.000	1.000	0.000	0.000	0.003	0.008	0.000
	Low	0.000	0.000	1.000	0.264	0.000	0.002	0.026
Growth	High	0.002	0.000	0.282	1.000	0.000	0.011	0.001
	Low	0.000	0.001	0.000	0.000	1.000	0.000	0.001
Variability	High	0.018	0.008	0.001	0.007	0.072	1.000	0.045
	Low	0.002	0.000	0.041	0.000	0.102	0.007	1.000

资料来源：Journal of Portfolio Management，天风证券研究所

也可以比较模型的收益差别，这种方法更关注模型产生 alpha 的能力。

4. 情景模型的合成与股票打分

图 8：情景模型的构建

EXHIBIT B-1

Hypothetical Model Weights

	A	B
High Growth Model	10%	70%
Low Growth Model	90%	30%

EXHIBIT B-2

Derived Factor Weights

	A	B	High Growth	Low Growth
RV	20.8%	9.4%	3.6%	22.7%
OE	20.0%	41.8%	52.7%	16.3%
AA	32.1%	21.7%	16.6%	33.8%
EF	16.3%	14.9%	14.2%	16.5%
MO	10.9%	12.2%	12.9%	10.6%

EXHIBIT B-3

Multiple Risk Dimensions

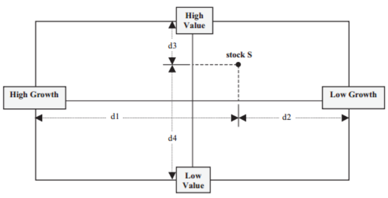

EXHIBIT B-4

Weights of Risk Dimensions

		Growth	Value
Model Weight	High	40%	90%
	Low	60%	10%
Contextual Weight		50%	50%

资料来源：Journal of Portfolio Management，天风证券研究所

本文通过股票风险特征动态确定因子权重的方法。可以有两种方式实现。第一种，在单一风险维度构建情景模型。例如，成长情景模型的因子权重来自于高成长模型和低成长模型。对于特定股票，其因子权重为两个模型的线性加权平均，而相应的权重取决于股票的增长率。第二种，在多风险维度构建情景模型。如图 8 所示。

分析师声明

本报告署名分析师在此声明：我们具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，本报告所表述的所有观点均准确地反映了我们对标的证券和发行人的个人看法。我们所得报酬的任何部分不曾与，不与，也将不会与本报告中的具体投资建议或观点有直接或间接联系。

一般声明

本报告是机密的，仅供我们的客户使用，天风证券不因收件人收到本报告而视其为天风证券的客户。本报告中的信息均来源于我们认为可靠的已公开资料，但天风证券对这些信息的准确性及完整性不作任何保证。本报告中的信息、意见等均仅供客户参考，不构成所述证券买卖的出价或征价邀请或要约。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐。客户应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求，必要时就法律、商业、财务、税收等方面咨询专家的意见。对依据或者使用本报告所造成的一切后果，天风证券及/或其关联人员均不承担任何法律责任。

本报告所载的意见、评估及预测仅为本报告出具日的观点和判断。该等意见、评估及预测无需通知即可随时更改。过往的表现亦不应作为日后表现的预示和担保。在不同时期，天风证券可能会发出与本报告所载意见、评估及预测不一致的研究报告。

天风证券的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。天风证券没有将此意见及建议向报告所有接收者进行更新的义务。天风证券的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

特别声明

在法律许可的情况下，天风证券可能会持有本报告中提及公司所发行的证券并进行交易，也可能为这些公司提供或争取提供投资银行、财务顾问和金融产品等各种金融服务。因此，投资者应当考虑到天风证券及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突，投资者请勿将本报告视为投资或其他决定的唯一参考依据。

投资评级声明

类别	说明	评级	体系
股票投资评级	自报告日后的 6 个月内，相对同期沪深 300 指数的涨跌幅	买入	预期股价相对收益 20%以上
		增持	预期股价相对收益 10%-20%
		持有	预期股价相对收益-10%-10%
		卖出	预期股价相对收益-10%以下
行业投资评级	自报告日后的 6 个月内，相对同期沪深 300 指数的涨跌幅	强于大市	预期行业指数涨幅 5%以上
		中性	预期行业指数涨幅-5%-5%
		弱于大市	预期行业指数涨幅-5%以下

天风证券研究

北京	武汉	上海	深圳
北京市西城区佟麟阁路 36 号	湖北武汉市武昌区中南路 99 号保利广场 A 座 37 楼	上海市浦东新区兰花路 333 号 333 世纪大厦 20 楼	深圳市福田区益田路 4068 号卓越时代广场 36 楼
邮编：100031	邮编：430071	邮编：201204	邮编：518017
邮箱：research@tfzq.com	电话：(8627)-87618889	电话：(8621)-68815388	电话：(86755)-82566970
	传真：(8627)-87618863	传真：(8621)-68812910	传真：(86755)-23913441
	邮箱：research@tfzq.com	邮箱：research@tfzq.com	邮箱：research@tfzq.com